



SpaceFarm AI

Plataforma de Monitoramento Agrícola Baseada em Observação Espacial e Inteligência Artificial

INTEGRANTES DO GRUPO

Richard Wrobel dos Santos — RM573998

Douglas Felicio da Silva — RM572312

Matheus Fontes — RM570457

QUERO CONCORRER

Global Solution 2026.1 — Grupo 62 — FIAP
github.com/mthsfontes/spacefarm-ai

1. Introdução

O **SpaceFarm AI** é uma plataforma de monitoramento agrícola baseada em **observação espacial**, **IoT**, **Inteligência Artificial** e **Ciência de Dados**.

A proposta da solução é auxiliar produtores rurais na identificação de situações de **estresse hídrico**, degradação da vegetação e necessidade de irrigação, utilizando dados ambientais e indicadores inspirados em tecnologias de observação da Terra por satélites.

O projeto aplica conceitos da **economia espacial** no agronegócio, demonstrando como dados derivados de observação terrestre podem apoiar decisões agrícolas mais eficientes, sustentáveis e baseadas em dados.

1.1 Problema Abordado

Produtores rurais muitas vezes enfrentam dificuldades para identificar rapidamente quando uma plantação está sofrendo com falta de água, baixa umidade do solo ou sinais de perda de vigor vegetal.

A ausência de monitoramento contínuo pode causar:

- desperdício de água;
- decisões tardias de irrigação;
- redução da produtividade;
- aumento de custos operacionais;
- dificuldade na análise da saúde da vegetação.


2. Desenvolvimento

2.1 Funcionamento da Solução

1. **Coleta de dados ambientais** — temperatura, umidade do ar, umidade do solo e luminosidade, gerados por um simulador de sensores IoT.
2. **Indicador espacial NDVI** — o sistema utiliza o **NDVI** (Normalized Difference Vegetation Index), indicador associado à observação terrestre por satélites, para representar a saúde da vegetação.
3. **Envio dos dados para a API** — as leituras são validadas e tratadas por uma API desenvolvida com **Flask**.
4. **Armazenamento em nuvem** — as informações são persistidas no **MongoDB Atlas**.

5. **Processamento e análise** — a biblioteca **Pandas** organiza e prepara os dados para o treinamento.
6. **Inteligência Artificial** — modelos de Machine Learning (**Decision Tree** e **Random Forest**) analisam os dados e recomendam ações, como a necessidade de irrigação.
7. **Visualização** — um dashboard **Streamlit** exibe indicadores ambientais, histórico, NDVI, risco hídrico e as previsões da IA em tempo real.

2.2 Arquitetura da Solução



2.3 Tecnologias Utilizadas

Tecnologia	Papel no projeto
Python	Linguagem principal do projeto
Flask	API para recebimento e integração dos dados
MongoDB Atlas	Banco de dados em nuvem
Pandas	Tratamento, organização e análise dos dados
Scikit-Learn	Criação dos modelos de Machine Learning
Streamlit	Dashboard interativo
NDVI	Indicador espacial de saúde da vegetação
Docker / Docker Compose	Execução padronizada de API, dashboard e simulador
GitHub Actions	Integração contínua — testes automatizados a cada push
Pytest	Suíte de testes da API e do serviço de predição

2.4 Inteligência Artificial

Os modelos analisam cinco variáveis ambientais e espaciais — **temperatura**, **umidade do ar**, **umidade do solo**, **luminosidade** e **NDVI** — para classificar cada leitura entre **irrigar** ou **não irrigar**, além de calcular o risco hídrico da lavoura.

Com base nesses dados, a IA:

- prevê a necessidade de irrigação com o nível de confiança da previsão;
- indica o risco hídrico e o índice geral da fazenda;
- explica a decisão por meio da importância de cada variável no modelo;
- compara o desempenho entre Decision Tree e Random Forest.

Comparação de Modelos (dados de teste — 20% do dataset):

Modelo	Accuracy	Precision	Recall
Decision Tree (produção)	98,0%	89,0%	86,7%
Random Forest	98,3%	93,9%	85,7%

A **Decision Tree** foi mantida como modelo em produção pela simplicidade, interpretabilidade e desempenho equivalente ao Random Forest neste conjunto de dados. As variáveis mais relevantes para a decisão são o **NDVI** e a **umidade do solo**, seguidas pela luminosidade — em linha com o conhecimento agrônômico do problema.

 **SpaceFarm AI**

Observação espacial + IoT + IA aplicadas à agricultura

API conectada

Leituras recentes

100

Última leitura: 09/06/2026 21:00:42


🤖 Inteligência Artificial

✅ Irrigação Não Necessária (confiança: 100%)

📋 Motivos da Recomendação

• Vegetação em possível estresse

🔍 O que a IA mais considera



Variável	Importância
Luminosidade	~0.23
NDVI	~0.35
Temperatura	~0.10
Umidade do Ar	~0.01
Umidade do Solo	~0.32

Importância de cada variável na decisão do modelo (Decision Tree).

⚖️ Comparação de Modelos

Modelo	Accuracy	Precision	Recall
Decision Tree	98.0%	89.0%	86.7%
Random Forest	98.3%	93.9%	85.7%

Deploy ⋮

Módulo de IA: previsão com confiança, motivos, importância das variáveis e comparação de modelos.

2.5 Dashboard

O dashboard do **SpaceFarm AI** apresenta de forma visual e interativa os indicadores ambientais, o histórico de medições, o módulo de observação espacial com o NDVI, o risco hídrico, as recomendações de irrigação e a comparação entre os modelos de IA. Os dados são atualizados automaticamente a cada 15 segundos.



Monitoramento ambiental em tempo real e módulo de observação espacial (NDVI).



Indicadores de risco hídrico e índice geral da fazenda, com recomendação automática.

2.6 Códigos Principais

Validação das leituras recebidas pela API (`backend/routes.py`):

```
CAMPOS_OBRIGATORIOS = ["temperatura", "umidade_ar", "umidade_solo", "luminosidade",

def validar_leitura(data):
    if not isinstance(data, dict):
        return "Corpo da requisição deve ser um JSON"
    for campo in CAMPOS_OBRIGATORIOS:
        if campo not in data:
            return f"Campo obrigatório ausente: {campo}"
        if not isinstance(data[campo], (int, float)) or isinstance(data[campo], bool):
            return f"Campo deve ser numérico: {campo}"
    return None
```

Geração da variável-alvo a partir do risco hídrico (`ml/create_target.py`):

```

df["risco_hidrico"] = (
    (df["temperatura"] * 0.3)
    + ((100 - df["umidade_solo"]) * 0.4)
    + ((df["luminosidade"] / 1000) * 10)
    + ((1 - df["ndvi"]) * 20)
)
df["irrigar"] = (df["risco_hidrico"] > 45).astype(int)

```

Treinamento do modelo de classificação (`ml/train_model.py`):

```

X = df[["temperatura", "umidade_ar", "umidade_solo", "luminosidade", "ndvi"]]
y = df["irrigar"]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
model = DecisionTreeClassifier()
model.fit(X_train, y_train)
accuracy = accuracy_score(y_test, model.predict(X_test))
joblib.dump(model, "ml/models/irrigation_model.pkl")

```

Serviço de predição consumido pelo dashboard (`ml/predict_service.py`):

```

def predict_irrigation(data):
    sample = pd.DataFrame([ { ... } ])          # leitura atual dos sensores
    prediction = model.predict(sample)[0]        # 1 = irrigar, 0 = não irrigar
    confidence = max(model.predict_proba(sample)[0])
    return prediction, confidence

```

3. Resultados Esperados

Com a POC em operação, espera-se que o produtor identifique condições de estresse hídrico em minutos — e não dias —, com recomendações de irrigação geradas automaticamente pela IA com acurácia de 98% nos dados de teste. Os principais resultados esperados são:



Redução do desperdício de água



Decisão baseada em dados



Monitoramento contínuo da plantação



Maior eficiência operacional



Uso prático da economia espacial



Agricultura mais sustentável

4. Instruções de Execução

Execução local

```
git clone https://github.com/mthsfontes/spacefarm-ai.git
cd spacefarm-ai/2TIA0/Global-Solution-1/src

python -m venv venv
source venv/bin/activate          # Windows: venv\Scripts\activate
pip install -r requirements.txt

cp .env.example .env              # preencher MONGO_URI com as credenciais

python -m backend.app              # terminal 1 – API (porta 5000)
python sensor_simulator.py         # terminal 2 – sensores IoT
streamlit run dashboard/app.py     # terminal 3 – dashboard (porta 8501)
```

Execução com Docker

```
cp .env.example .env              # preencher MONGO_URI
docker compose up --build          # sobe API, dashboard e simulador
```

Testes automatizados

```
pip install pytest mongomock
pytest tests/ -v
```

5. Conclusões

O **SpaceFarm AI** demonstra como tecnologias de observação espacial, IoT e Inteligência Artificial podem ser combinadas para criar uma solução agrícola inteligente, eficiente e sustentável.

A plataforma contribui para o uso mais consciente da água, melhora o acompanhamento da saúde da vegetação e auxilia produtores na tomada de decisões com base em dados.

6. Links da Entrega

- Repositório do projeto: <https://github.com/mthsfontes/spacefarm-ai>
- Vídeo demonstrativo (YouTube, não listado): <https://youtu.be/b45cHwczgPU>